UBA EXACTAS

Título titularilozo

Laboratorio de Datos
Marzo 2026

Departamento de Computación
Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Integrantes:
Tobías Passarelli
Santiago Pizzani Esteban

Docentes:
Pablo Turjanski
Manuela Cerdeiro
María Clara Fontana

Resumen

En este trabajo se aborda el problema de la clasificación de caracteres del alfabeto inglés a partir de imágenes tipográficas. Se realizó un análisis exploratorio de datos (EDA) sobre un dataset de 26.416 instancias, confirmando un balance perfecto entre las 26 clases. Se implementaron dos aproximaciones de modelado supervisado: una clasificación binaria (letras ”**O**”vs. ”**L**”) mediante el algoritmo K-Nearest Neighbors (KNN), y una clasificación multiclase para la totalidad del alfabeto utilizando Árboles de Decisión. Mediante validación cruzada y una partición de datos en tres etapas (Entrenamiento, Validación y Held-out), se optimizaron los hiperparámetros de los modelos. El modelo final basado en árboles de decisión alcanzó una exactitud del 77.89 % en datos no vistos, demostrando la viabilidad del enfoque propuesto para el reconocimiento de caracteres.

1. Introducción

El presente trabajo busca caracterizar el conjunto de datos llamado *English Typed Alphabet*, previo a la implementación de modelos de aprendizaje automático. El dataset está compuesto por imágenes de caracteres tipográficos en escala de grises, donde cada fila representa un píxel de la imagen transformada en vector, en el mismo se incluyen las 26 letras del alfabeto inglés, capitalizadas, y con múltiples versiones de cada letra.

Para lograr dicho objetivo, se buscará crear dos modelos de aprendizaje supervisado aplicando el modelo de K-Nearest Neighbors (KNN) y el de Árboles de Decisión, por lo que vale la pena ahondar en el marco teórico existente detrás de cada uno de ellos. [2]

1.1. Modelo K-Nearest Neighbors (KNN)

Se trata de uno de los algoritmos de aprendizaje supervisado más intuitivos del machine learning. Su funcionamiento es relativamente sencillo, y consiste en que un dato nuevo se clasifica según los datos más cercanos a él, esto se representa mediante un espacio de n-dimensiones diseñado a partir de los datos de entrenamiento [1]. El modelo memoriza la posición de cada uno de los puntos de ese set de entrenamiento, y al ingresar un nuevo dato que requiere ser clasificado, se seleccionan los K vecinos más cercanos, esa cercanía se calcula mediante la distancia euclidiana, fórmula disponible en la Ecuación 1, donde a_r es tal, x_i es no se que y X_j es tal y tal cosa.

$$d(x_i, x_j) \equiv \sqrt{\sum_{r=1}^{n} (a_r(x_i) - a_r(x_j))^2} \tag{1}$$

La clase asignada al nuevo dato corresponde al valor más frecuente entre los K vecinos seleccionados, es decir, se determina por votación mayoritaria [1]. El parámetro K juega un rol fundamental en el comportamiento del modelo: cuando $K = 1$, el algoritmo simplemente asigna al nuevo dato la clase del vecino más cercano. Para valores mayores de K, se considera el valor más común entre los K ejemplos de entrenamiento más próximos [1].

1.2. Modelo de Árbol de Decisión

Esta clase de modelos se caracterizan por realizar una serie de preguntas al conjunto de datos para así poder clasificar nueva información. Se construyen mediante una sucesión de preguntas si/entonces, lo que lleva al modelo a tomar una decisión [2].

Estructuralmente, un árbol de decisión se compone de nodos, ramas y hojas. Cada nodo determina una prueba sobre algún atributo del dato a clasificar, cada rama representa uno de los posibles valores de ese atributo, y las hojas corresponden a los nodos terminales que determinan la clase asignada [1]. Además, la profundidad del árbol indica la máxima cantidad de preguntas realizadas para llegar a una decisión.

El proceso de clasificación comienza en el nodo raíz, donde se evalúa el atributo correspondiente y se desciende por la rama asociada al valor del dato. Este proceso se repite en cada nodo hasta alcanzar una hoja [1].

1.3. Exactitud y Complejidad de un Modelo

Los modelos entrenados usan dos tipos de datos: Datos de entrenamiento y datos de prueba (test). Para evaluar qué tan bien se desempeña el modelo al clasificar los datos se usa la métrica de la exactitud, esta nos dice qué tan capaz es el modelo de asignarle la clasificación correcta a un dato. Existe un balance entre qué tan exacto es el modelo sobre los datos de entrenamiento respecto a la exactitud que tiene al momento de generalizar para nuevos datos [2]. Un modelo demasiado exacto en los datos de entrenamiento suele presentar sobreajuste (overfitting), mientras que uno con baja exactitud se dice que presenta subajuste (underfitting). Un ejemplo de esto se puede apreciar en la Figura 1, donde se observa un punto ideal donde la exactitud para los datos generalizados encuentra un balance con la complejidad del modelo.

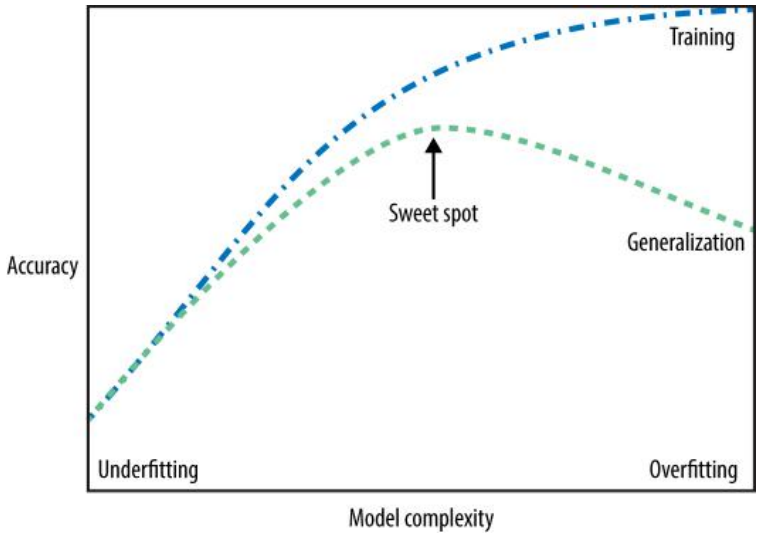

Figura 1: Esquema del balance entre complejidad del modelo y exactitud en los resultados. La curva azul presenta la exactitud para datos con los que se entrenó el modelo, mientras que la curva verde es la exactitud al generalizar los resultados del entrenamiento a un conjunto externo de datos (nuevos datos). Figura extraída de [2].

1.4. Metodología de Trabajo

El estudio se estructuró en tres fases incrementales de complejidad:

- **Análisis Exploratorio y Distancias:** Evaluación de la variabilidad interna de los caracteres y cálculo de distancias euclídeas para medir la similitud entre morfologías (ej. O vs. Q).
- **Clasificación Binaria (KNN):** Implementación de un modelo de vecinos más cercanos para distinguir entre O y L, analizando el impacto de la selección de atributos según su varianza.
- **Clasificación Multiclase (Árboles de Decisión):** Entrenamiento de modelos para la totalidad del alfabeto, utilizando técnicas de Validación Cruzada (K-Folding) para la selección de hiperparámetros y un conjunto de evaluación final (Held-out) para medir la capacidad de generalización.

2. Análisis Exploratorio de Datos

Antes del modelado, se analizó la estructura espacial y la variabilidad del dataset para comprender la naturaleza del problema de clasificación. Para ello, se empezó por analizar la validez de los modelos entrenados, se realizó una auditoría inicial de los datos obteniendo las siguientes métricas:

- **Volumen de datos:** 26.416 instancias.
- **Dimensionalidad:** Cada imagen representa una letra en mayúscula del abecedario inglés, a la vez que cuenta con 784 atributos representados en un una imagen rectangular de 28×28 píxeles en escala de grises. Es decir, las celdas de los píxeles pueden tomar valores enteros entre 0 y 255.
- **Balance de clases:** El conjunto está perfectamente balanceado, con 1.016 muestras por cada una de las 26 letras del alfabeto. Esto permite que la métrica de Exactitud (Accuracy) sea un indicador fiel del rendimiento del modelo sin sesgos por frecuencia de clase.

2.1. Varianza de Píxeles y Selección de Atributos

Se calculó la varianza de cada uno de los 784 píxeles a través de todas las instancias. Este análisis permitió identificar que la información discriminatoria se concentra en la región central del cuadrante de 28×28.

- **Bordes:** Presentan varianza nula o cercana a cero, indicando que los píxeles cercanos a los bordes no aportan información útil para la clasificación.
- **Centro:** Presenta los mayores niveles de varianza, donde se ubican los trazos característicos de cada letra.

2.2. Similitud Morfológica y Distancia Euclídea

Para cuantificar qué tan parecidas son dos letras entre sí en el espacio de representación, se utilizó la métrica de Distancia Euclídea entre sus vectores de intensidad promedio. Al realizar este cálculo para distintas combinaciones, un par de particular interés resultó ser el de las letras O y Q. Se observó que la distancia promedio entre ambas es significativamente menor que la existente entre pares disímiles, como O y L o S y M. Este hallazgo confirma que solo una reducida proporción de píxeles —principalmente aquellos correspondientes a la $''cola''$ inferior derecha de la Q— permite diferenciar ambas clases. Esta proximidad espacial representa un claro desafío para algoritmos de clasificación basados puramente en distancias, como es el caso de K-Nearest Neighbors (KNN).

2.3. Variabilidad Intra-clase: El Caso de la Letra J

Además de la distancia entre distintas clases, resulta fundamental evaluar la heterogeneidad interna de un mismo label. La clase J fue seleccionada para este análisis específico debido a su notoria diversidad morfológica a lo largo del dataset. Las instancias analizadas presentan evidentes alteraciones en la estructura del trazo, incluyendo variaciones pronunciadas en la curvatura inferior e incluso la adición u omisión de remates horizontales superiores dependiendo de la tipografía. Para obtener una métrica de dispersión que cuantifique este fenómeno de manera objetiva, se calculó la distancia euclídea de cada muestra respecto al vector de intensidad promedio de la letra J. La media de esta distancia se sitúa en 1.677,5, evidenciando un alto grado de variabilidad interna de esta clase en particular.

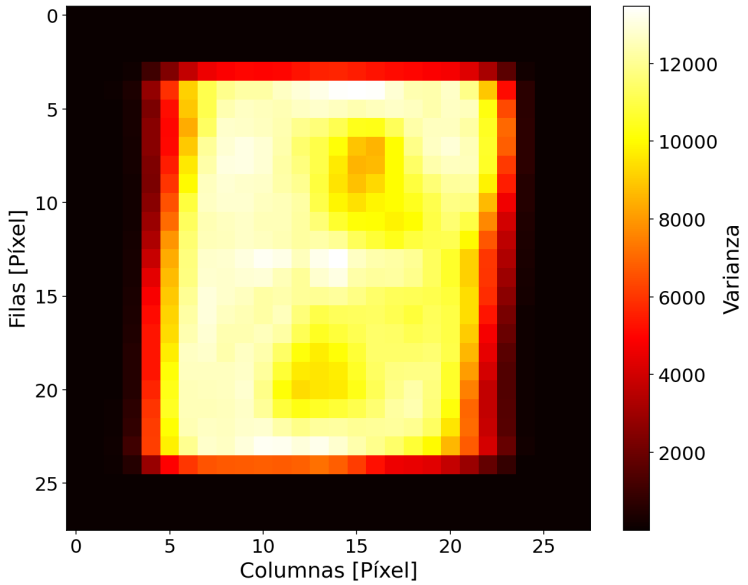

Figura 2: Mapa de calor con la varianza por píxel para la totalidad del dataset. Los píxeles de los bordes presentan varianza cercana a cero, mientras que la región central posee la mayor varianza.

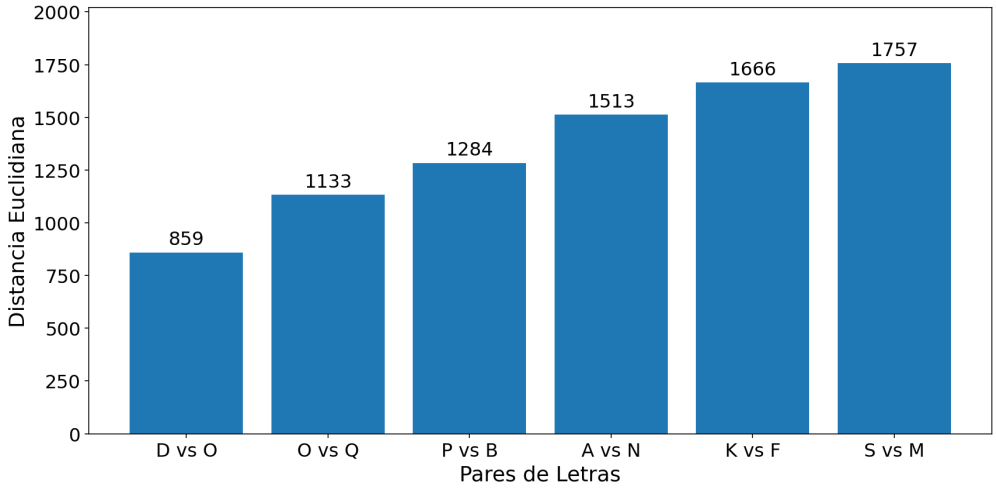

Figura 3: Distancia euclidiana para distintos pares de letras: a mayor distancia, más se diferencian entre sí. Se observa que D y O son las más parecidas, mientras que S y M son las más diferentes.

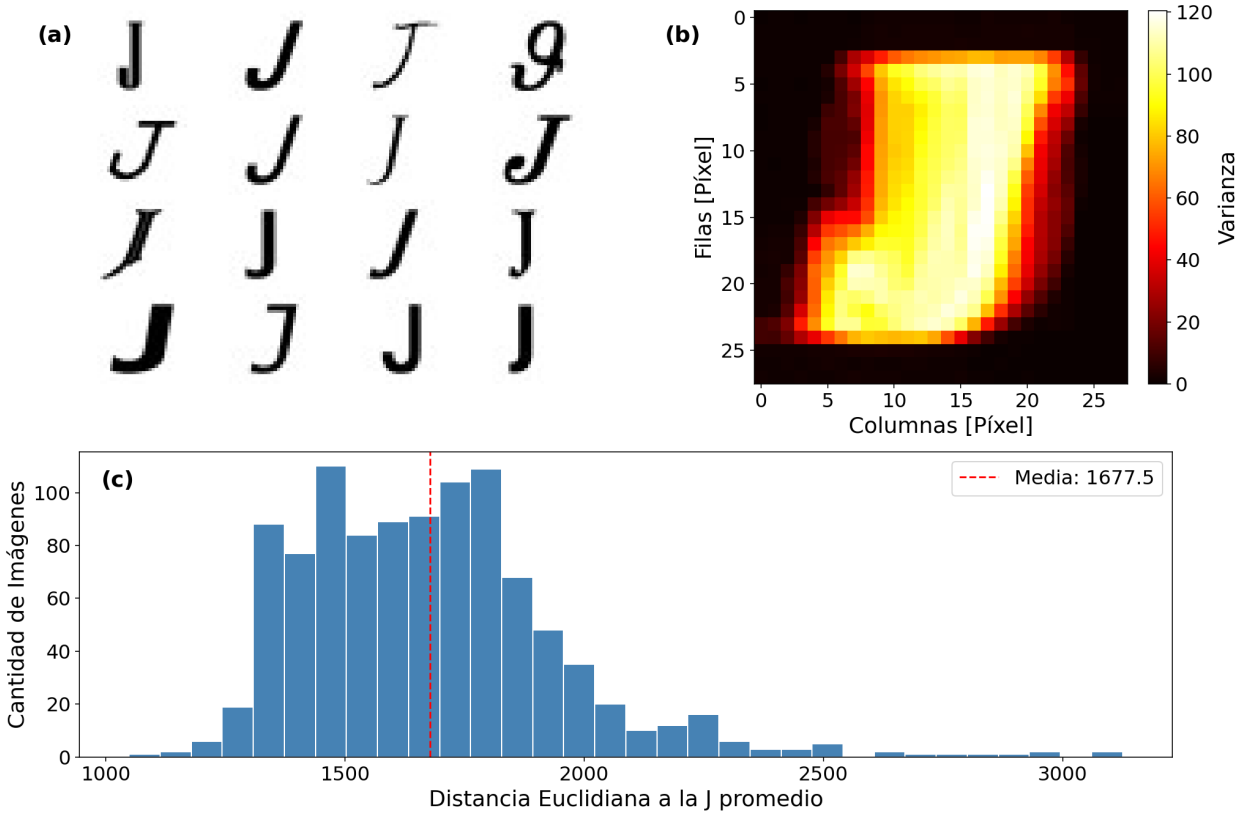

Figura 4: Variación existente entre las imágenes para la letra J. **(a)** Distintas presentaciones para la letra J presentes en el dataset. **(b)** Mapa de calor con la varianza por píxel. **(c)** Distancia Euclidiana a la J promedio, calculada como el píxel promedio entre todas las imágenes del carácter.

3. Clasificación Binaria

En esta sección se abordó el problema de separar dos clases con diferencias morfológicas evidentes: la O y la L, utilizando el algoritmo K-Nearest Neighbors (KNN). Para evitar el sesgo de datos, las transformaciones y el cálculo de varianzas se realizaron exclusivamente sobre el conjunto de entrenamiento.

3.1. Impacto de la Selección de Atributos

Para evaluar la importancia de la información espacial, se entrenaron modelos KNN incrementando progresivamente la cantidad de píxeles utilizados (3, 10, 50, 100 y 200). Se contrastó el rendimiento al seleccionar los píxeles con mayor varianza versus aquellos con menor varianza (periferia de la imagen).

Como ilustra la Figura 5, el modelo alimentado con los píxeles de alta varianza alcanza rápidamente exactitudes cercanas al 100 %. Por el contrario, utilizar los píxeles de menor varianza produce resultados iniciales cercanos al nivel de azar (50 %), lo que demuestra empíricamente que la información discriminativa del carácter se concentra en las zonas de alta variabilidad espacial.

3.2. Optimización del Hiperparámetro K

Una vez comprobada la eficacia de la selección de atributos, se fijó el espacio de características en los 50 píxeles más variables para buscar la configuración óptima del modelo. Se evaluó la exactitud variando la cantidad de vecinos (K) desde 1 hasta 20.

La Figura 6 expone la curva de complejidad del modelo. Cuando $K = 1$, el algoritmo memoriza el conjunto de entrenamiento (exactitud del 100 %), lo que es un claro síntoma de sobreajuste (*overfitting*). A medida que K aumenta, la frontera de decisión se vuelve más suave. El valor $K = 3$ representa el punto de equilibrio óptimo (*Sweet Spot*), ya que logra maximizar la exactitud sobre el conjunto de prueba sin un nivel de complejidad excesivo. Para valores de $K \geq 4$, el modelo comienza a presentar subajuste (*underfitting*), degradando su capacidad predictiva.

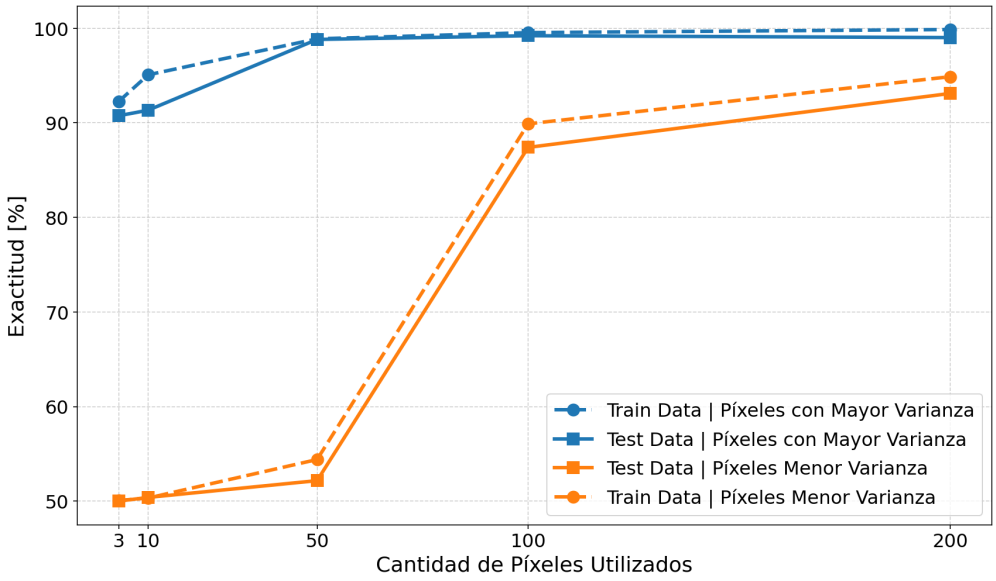

Figura 5: Exactitud del modelo para clasificar entre O y L en función de los píxeles utilizados. Líneas azules representan los píxeles de mayor varianza, las naranjas los de menor varianza. Además de la cantidad, también importan qué píxeles se eligen para entrenar al modelo.

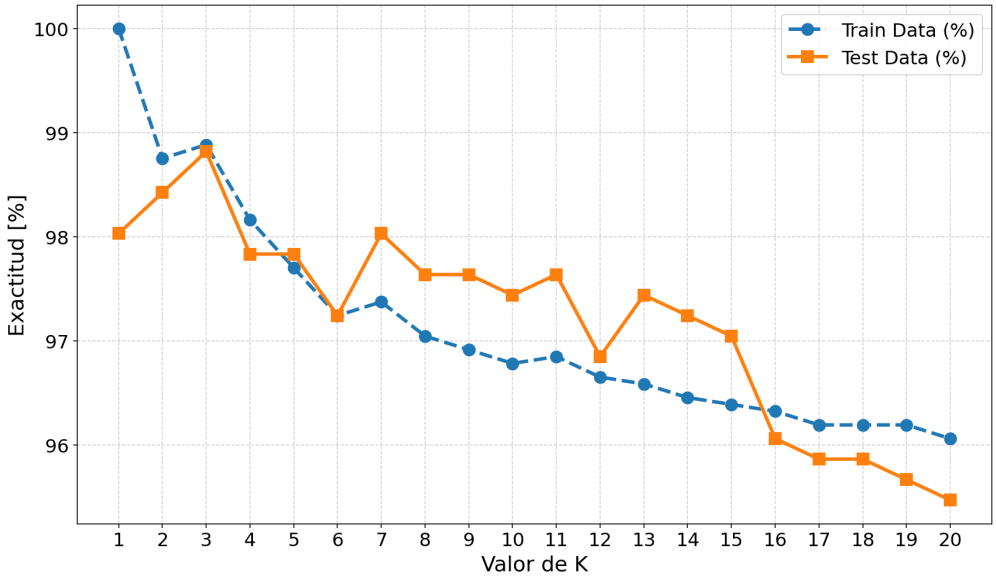

Figura 6: Valores para la exactitud al clasificar las letras O y L en función del valor de K para un modelo que usa los 50 píxeles con mayor varianza. $K = 3$ resulta ser el valor óptimo que maximiza resultados para el test data sin tener un modelo extremadamente simple ni complejo.

4. Clasificación Multiclase

Habiendo explorado la separabilidad binaria, en esta sección se aborda el problema completo: clasificar las 26 letras del alfabeto simultáneamente. Dada la mayor complejidad del espacio de

decisión, se optó por utilizar un modelo de Árboles de Decisión, el cual permite capturar reglas no lineales y particiones jerárquicas del espacio de atributos.

4.1. Selección de Hiperparámetros mediante Grid Search

Para encontrar la configuración óptima del modelo y evitar el sobreajuste (*overfitting*), se implementó una búsqueda exhaustiva en grilla (*Grid Search*) combinada con validación cruzada de 5 pliegues ($K = 5$) sobre el conjunto de desarrollo. Se evaluaron dos dimensiones de hiperparámetros:

- **Criterio de Impureza:** Índice de Gini vs. Entropía (Ganancia de Información).
- **Profundidad Máxima (*max_depth*):** Valores enteros en el rango de 1 a 10.

Como se detalla en la Tabla 1, el criterio basado en Entropía demostró una superioridad en la capacidad de generalización respecto a Gini. Asimismo, la profundidad de 10 niveles resultó ser el punto de equilibrio (*Sweet Spot*) de complejidad, alcanzando una exactitud media del 80.48 % durante la validación cruzada.

Criterio de Impureza	Profundidad Máxima	Exactitud Media (CV)
Entropía	10	80.48 %
Gini	10	76.83 %

Tabla 1: Resultados de la validación cruzada. La Entropía con profundidad 10 fue la configuración óptima.

4.2. Evaluación Final y Análisis de Errores

Utilizando la configuración óptima, se reentrenó el árbol de decisión con la totalidad del conjunto de desarrollo y se lo evaluó, por única vez, sobre el conjunto *Held-out*. El modelo alcanzó una **exactitud final del 80.03 %**. La extrema similitud con la métrica de validación cruzada confirma que el modelo es robusto y generaliza correctamente sobre datos no vistos.

Para comprender la naturaleza del $\sim$20 % de clasificaciones erróneas, se analizó la Matriz de Confusión (Figura 7). Se observó que el modelo es altamente preciso para caracteres con trazos únicos (como la `F` o la `X`), pero concentra sus fallas en pares con alta similitud morfológica estructural. El caso más crítico es la confusión entre `I` y `J` (24 errores), seguido por las confusiones simétricas entre `O` y `Q`. Estos resultados empíricos validan las observaciones de cercanía espacial calculadas mediante distancias euclídeas en la etapa de Análisis Exploratorio.

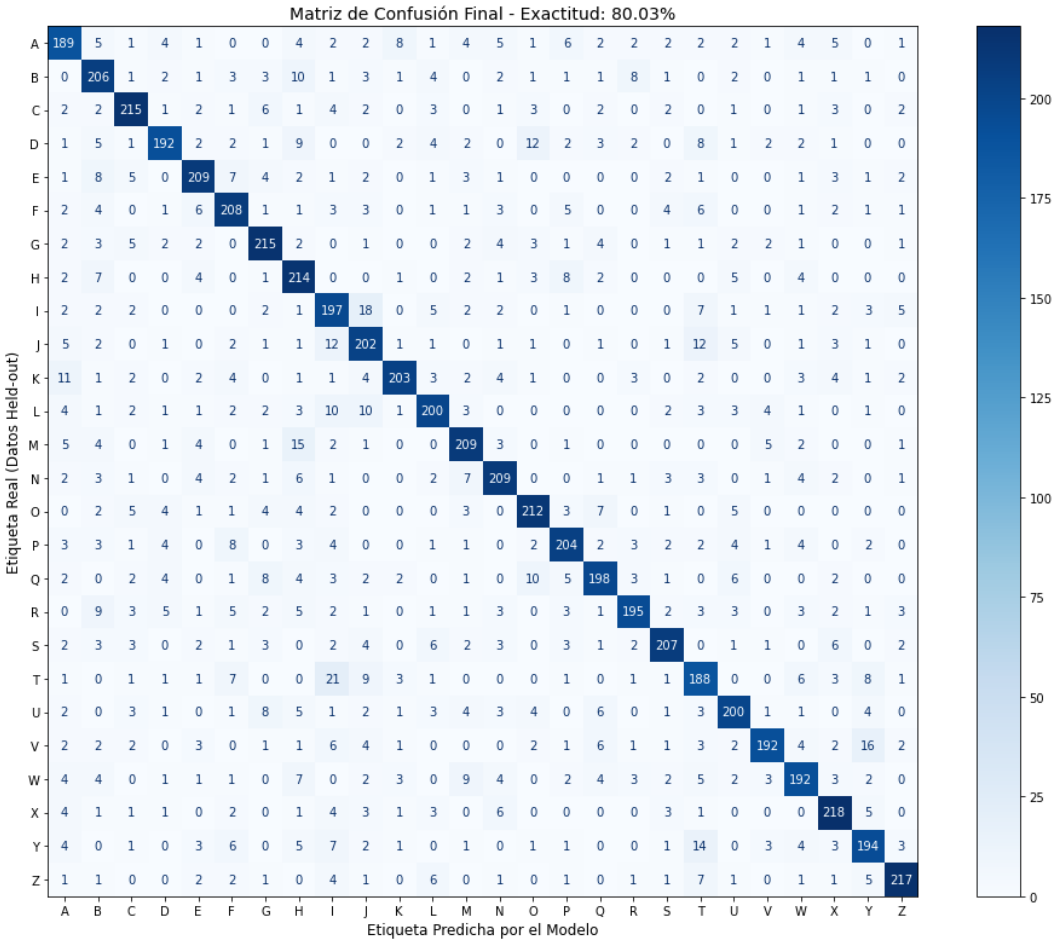

Figura 7: Matriz de confusión multiclase evaluada sobre el conjunto Held-out. Se destacan los aciertos en la diagonal principal y las confusiones específicas fuera de ella (ej. I vs J).

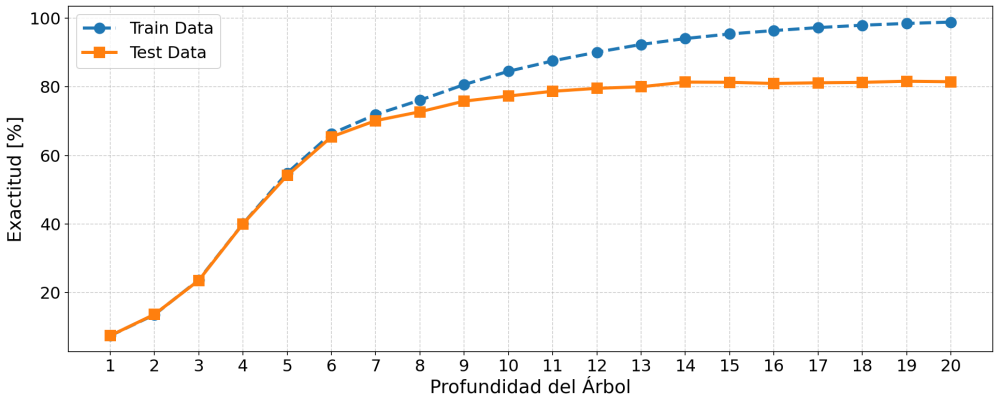

Figura 8: Exactitud del árbol de decisión al clasificar letras del abecedario según la profundidad. Rango ideal entre exactitud y complejidad sucede entre profundidad 8 y 10; a valores mayores se entra en sobreajuste (overfitting).

5. Conclusiones

El presente trabajo permitió abordar el problema de clasificación multiclase de imágenes tipográficas desde sus fundamentos exploratorios hasta la evaluación de modelos predictivos. A partir del Análisis Exploratorio de Datos (EDA), se demostró que si bien el balance perfecto de clases favorece el modelado, la similitud morfológica intrínseca entre ciertos pares de caracteres (tales como I vs. J u O vs. Q) impone un desafío natural para la separabilidad en un espacio de 784 dimensiones.

La metodología de partición de datos (Entrenamiento, Desarrollo y *Held-out*) garantizó una evaluación robusta y libre de sesgos metodológicos (*Data Leakage*). Durante la etapa de optimización, la búsqueda exhaustiva de hiperparámetros (*Grid Search*) mediante validación cruzada ($K = 5$) reveló que el criterio de partición basado en la **Entropía** (Ganancia de Información) superó al Índice de Gini para este dominio. Asimismo, limitar la profundidad máxima del árbol a 10 resultó ser el punto de equilibrio óptimo entre la capacidad predictiva y la prevención del sobreajuste (*overfitting*).

Finalmente, el modelo definitivo fue evaluado sobre el conjunto *Held-out*, logrando una **Exactitud del 80.03 %** en datos nunca antes vistos. La extrema cercanía entre esta métrica final y la obtenida durante la validación cruzada (80.48 %) certifica la excelente capacidad de generalización del modelo construido.

Si bien el rendimiento es altamente satisfactorio para un modelo de árbol simple, los errores observados en la matriz de confusión indican que para superar la barrera del 80 % de exactitud y distinguir los detalles morfológicos más sutiles, el trabajo futuro requeriría la implementación de métodos más complejos, tales como ensambles de árboles (*Random Forest*) o técnicas de extracción de características no lineales.

Referencias

[1] TM Mitchell. *Machine Learning*. McGraw-Hill International, 1997.

[2] Andreas C Müller and Sarah Guido. *Introduction to machine learning with Python: a guide for data scientists*. O'Reilly Media, Inc., 2016.